

IIM — Hướng dẫn Clone, Setup & Chạy Demo

AI Incident Analysis Layer for SRE / On-call — LLM-SRE (nội danh IIM)

Repo chạy toàn bộ stack bằng Docker Compose (Postgres + pgvector, backend FastAPI, frontend React). Hướng dẫn này dùng `claude_cli` làm LLM provider (Claude Code subscription cá nhân, không tốn phí API riêng). Thời gian setup lần đầu: khoảng 15 phút (chủ yếu chờ build Docker và đăng nhập Claude Code).

1. Yêu cầu trên máy demo

- Docker Desktop (hoặc Docker Engine + Compose) đã cài và đang chạy.
- Claude Code CLI đã cài (`npm install -g @anthropic-ai/claude-code`) và có subscription Claude Pro/Max — dùng để lấy token cho `claude_cli` provider.
- `git` để clone repo.

2. Clone repo và checkout branch

```
git clone https://github.com/emesoft/sre-iim.git LLM-SRE
cd LLM-SRE
git checkout main # hoặc nhánh/tag đã merge tính năng demo này
```

3. Tạo file `.env` ở thư mục gốc

`.env` bị gitignore, phải tự tạo (tham khảo `backend/env.example`). Tối thiểu cần các biến sau:

```
# --- Database ---
POSTGRES_DB=iim
POSTGRES_USER=iim
DB_PASSWORD=change-me # tự đặt password khác nếu muốn

# --- LLM provider ---
LLM_PROVIDER=claude_cli
CLAUDE_CLI_MODEL=sonnet # hoặc opus/haiku
ANALYSIS_MODE=single # single = 1 lần gọi LLM/phân tích (khuyến nghị ch
MAX_ROUNDS=2

# --- Embedding (RAG) — dùng Jina, free tier, không cần AWS ---
EMBEDDING_PROVIDER=jina
EMBEDDING_MODEL=jina-embeddings-v3
EMBEDDING_DIM=768
JINA_API_KEY=jina... # lấy free tại jina.ai/embeddings

# --- Mã hóa secrets (AWS access key, ADO PAT, Claude Code token đều lưu mã hóa trong D
SECRET_ENCRYPTION_KEY= # sinh bằng lệnh dưới
```

```
# --- Password admin để vào trang Settings ---
ADMIN_PASSWORD=                # tự đặt
ADMIN_JWT_SECRET=              # sinh bằng lệnh dưới
```

```
# Sinh SECRET_ENCRYPTION_KEY:
python -c "from cryptography.fernet import Fernet; print(Fernet.generate_key().decode())"

# Sinh ADMIN_JWT_SECRET:
python -c "import secrets; print(secrets.token_urlsafe(32))"
```

Bắt buộc: `SECRET_ENCRYPTION_KEY` và `ADMIN_PASSWORD` / `ADMIN_JWT_SECRET` — thiếu thì trang Settings và mọi thao tác lưu secret (AWS connection, ADO PAT, Claude Code token) sẽ báo lỗi 503/500 thay vì hoạt động.

4. Khởi động stack

```
docker compose up -d --build
```

Chờ tới khi backend chạy xong migration. Kiểm tra:

```
curl localhost:8000/healthz
# {"status":"ok","app":"IIM","database":"up"}
```

Mở <http://localhost:5173>. Trang chủ dùng gate đăng nhập tạm ở frontend (nhập email bất kỳ → Sign in) — SSO thật chưa làm.

5. Cấu hình Claude Code token (bắt buộc để phân tích chạy được)

Trên **chính máy đang chạy** `docker compose` (không phải trong container):

```
claude setup-token
```

Lệnh này mở trình duyệt đăng nhập Claude Code, in ra một token. Copy token đó, vào app:

Settings → nhập `ADMIN_PASSWORD` → mục **Claude Code token** → dán token → **Save**.

Token được mã hóa và lưu trong Postgres, không lưu ở `.env`. Nếu quên bước này, mọi incident sẽ phân tích **failed** — nút **Retry analysis** sẽ hoạt động lại ngay sau khi cấu hình token xong (không cần tạo incident mới).

6. Nạp Knowledge Base

Vào **Knowledge Base** → bấm **Load default runbooks**. App tự ingest 3 runbook mẫu: High CPU/Memory, 5xx Error Spike, Deploy Rollback. Bấm lại nhiều lần vẫn an toàn (không tạo trùng, không tốn phí embed lại).

7. Cấu hình Project (AWS + Azure DevOps) — tùy chọn

Mục **Projects** trong Settings gộp chung: tên project (registry chung), Azure DevOps (organization, project, PAT, work item type), và AWS connection (SSO profile hoặc Access key).

Không bắt buộc cho luồng demo chính (tạo incident thủ công → phân tích → tạo ticket) — chỉ cần nếu muốn demo auto-ingest CloudWatch alarm thật hoặc nút "Create ADO ticket".

AWS connection — SSO profile (khuyến nghị)

```
# Trên máy host:
aws configure sso
# SSO start URL: https://your-org.awsapps.com/start
# SSO region: <region IAM Identity Center đang chạy>
# → chọn account/role → đặt tên profile, ví dụ: rxdevs-prod-readonly

aws sso login --profile rxdevs-prod-readonly

# Xác nhận quyền trước khi vào app:
aws cloudwatch describe-alarms --profile rxdevs-prod-readonly --max-records 1
```

Vào app → Settings → Projects → thêm AWS connection → chọn **SSO profile** → gõ đúng tên profile (app không tự liệt kê danh sách).

Token SSO có hạn (vài giờ) — hết hạn thì chạy lại đúng lệnh `aws sso login --profile <name>`, không cần sửa gì trong app.

Azure DevOps connection

PAT cần quyền **Work Items (Read & Write)** trên project ADO tương ứng. Bấm **Test** sau khi thêm để xác nhận org/project/PAT hợp lệ.

8. Kịch bản demo (gợi ý, ~10 phút)

1. **Đăng nhập** (10s) — nhập email bất kỳ → Sign in. (Gate tạm ở frontend, Settings có xác thực admin thật riêng.)
2. **Tạo incident** (2 phút) — Incidents → New incident → chọn sample *Infra OOM* → Create. Theo dõi các stage chạy real-time qua SSE. Chỉ vào Severity/Summary, Root cause (nổi `recent_deploy` với metric bất thường), Recommended action, và Evidence (trích dẫn đúng runbook đã nạp).
3. **Chat with Claude** (2 phút) — hỏi tự nhiên trong panel chat, Claude tự quyết định gọi tool lấy log khi cần.
4. **Resolve & Known-issue matching** (2 phút) — Resolve incident, tạo incident thứ hai cùng sample nhưng đổi `recent_deploy.version` → banner "Known issue" xuất hiện.
5. **Tạo ADO ticket** (1 phút, cần đã cấu hình ADO) — ticket tự có Related link nếu là ca lặp lại.
6. **Báo cáo ngày** (1 phút) — Reports → chọn ngày → Generate report → Copy for Slack.

9. Xử lý sự cố lúc demo

Triệu chứng	Nguyên nhân thường gặp	Xử lý
UI hiện "can't reach the backend"	backend chưa lên xong	chờ hết migration, <code>docker compose logs backend</code>
"Claude Code token is not configured"	quên bước 5	vào Settings dán token, bấm Retry analysis
Evidence rỗng	không có runbook liên quan, hoặc thiếu <code>JINA_API_KEY</code>	kiểm tra key, hoặc bình thường nếu incident không liên quan
"Create ADO ticket" lỗi 422	chưa cấu hình ADO cho project	Settings → Projects thêm ADO
"Create ADO ticket" lỗi 502	PAT hết hạn/thiếu quyền/work item type sai	kiểm tra PAT, bấm Test
Bấm Create ADO ticket lần 2 báo 409	incident đã có ticket (đúng hành vi)	dùng link ticket cũ trong lỗi
Settings báo lỗi 503	thiếu <code>ADMIN_PASSWORD</code> / <code>ADMIN_JWT_SECRET</code>	thêm vào <code>.env</code> , rebuild backend
Lưu connection/token báo lỗi 500	thiếu <code>SECRET_ENCRYPTION_KEY</code>	thêm vào <code>.env</code> , rebuild backend
Muốn reset toàn bộ dữ liệu demo	—	<code>docker compose down -v && docker compose up --build</code> (mất hết dữ liệu)

Phương án dự phòng: chạy thử trọn kịch bản một lượt trước buổi demo thật, giữ nguyên dữ liệu trong DB — nếu mạng/API chết lúc demo, vẫn còn incident đã phân tích sẵn để trình bày.

10. Giới hạn — nên chủ động nói trước

- Đăng nhập trang chính chỉ là gate tạm ở frontend (email bất kỳ đều vào được). Settings có xác thực admin thật (1 password dùng chung, không phải per-user).
- Auto-ingest CloudWatch alarm cần AWS connection thật — không bật sẵn theo mặc định.
- `claude_cli` chỉ dùng cho demo/dev, không phải kiến trúc production.
- Chỉ chạy local qua Docker Compose — chưa deploy lên cloud thật (Terraform `iac/` còn rỗng).

11. Đổi sang LLM provider khác (không có Claude Code subscription)

DeepSeek / OpenRouter (free tier, cần API key):

```
LLM_PROVIDER=deepseek
DEEPSEEK_API_KEY=sk-or-...
```

```
DEEPSEEK_MODEL=openai/gpt-oss-20b:free
DEEPSEEK_BASE_URL=https://openrouter.ai/api/v1
```

Bedrock (mất phí, cần quyền AWS thật):

```
LLM_PROVIDER=bedrock
AWS_REGION=ap-southeast-1
MODEL_ID=anthropic.claude-3-5-haiku-20241022-v1:0
EMBEDDING_PROVIDER=titan
EMBEDDING_DIM=1024          # đổi dim so với Jina cần tạo lại DB: docker compose down -v
```

Đổi `EMBEDDING_PROVIDER` / `EMBEDDING_DIM` sau khi DB đã có dữ liệu **không tự resize** — phải `docker compose down -v` (mất toàn bộ dữ liệu) rồi `up --build` lại từ đầu.